

Генеративные потоковые сети и МСМС для обучения структуры байесовских сетей

Отчет НИР, осень 2025

Алтай Эйнуллаев Эльшан оглы

Научный руководитель: к.ф-м.н. С.В.Самсонов

Кафедра интеллектуальных систем ФПМИ МФТИ

2025

Проблема

Генеративные потоковые сети – подход к обучению структуры байесовских сетей. Несмотря на то, что этот метод позволяет очень быстро сэмплировать из апостериорного распределения, последние исследования показывают, что он уступает МСМС по качеству сэмплирования.

Предлагаемый подход

Предлагается применить последние подходы к улучшению МСМС для генеративных потоковых сетей.

Обучение структуры байесовских сетей

Определение

Байесовская сеть (G, Θ_G) – вероятностная модель над $\mathbf{X} = \{X_1, X_2, \dots, X_d\}$:

$$p(\mathbf{X}|G, \Theta_G) = \prod_{i=1}^d p(X_i | \text{Pa}_G(X_i), \Theta_i),$$

где $\text{Pa}_G(X_i)$ – множество родителей вершины X_i в ориентированном, ациклическом графе G , Θ_G – множество параметров модели, Θ_i – множество параметров распределения $p(X_i | \text{Pa}_G(X_i))$.

Постановка задачи

$D = (\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(N)}) \sim (G^*, \Theta_{G^*}^*)$. Ставится задача сэмплирования G (структуры байесовской сети):

$$G \sim p(G|D),$$

при заданных $p(G), p(\Theta_G|G), p(\mathbf{X}|G, \Theta_G)$.

Обучение структуры байесовских сетей

По формуле Байеса:

$$p(G|D) = \frac{p(D, G)}{p(D)} \propto p(D, G) = \int_{\Theta_G} p(D|G, \Theta_G) p(\Theta_G|G) p(G) d\Theta_G = R(G).$$

Условие модулярности

Для любых G, G' , т.ч. $\text{Pa}_G(X_i) = \text{Pa}_{G'}(X_i)$, выполняется:

$$p(\Theta_i|G) = p(\Theta_i|G').$$

Факторизация $R(G)$

$$R(G) = \prod_{i=1}^d \text{LocalScore}(X_i | \text{Pa}_G(X_i)).$$

Базовый метод МСМС для сэмплирования из $p(G|D)$

Схема Метрополиса-Гастингса

G_0 — начальное состояние

$G' \sim Q(G'|G_t)$ — сэмплируем из предложного распределения

$\alpha(G_t, G') = \min\left\{1, \frac{P(G'|D)Q(G_t|G')}{P(G_t|D)Q(G'|G_t)}\right\}$ — принимаем сэмпл

Соседи G_t

Соседи G_t образуются удалением, добавлением, обращением ребра (i, j) .

Генерация G'

- $i, j \sim q_{ij}$
- $G_t \rightarrow G'$
- Проверяем ацикличность G'
- $\alpha(G_t, G') = \min\left\{1, \frac{P(G'|D)}{P(G_t|D)}\right\}$ — вероятность обновления состояния

Модификации метода

Проблемы

- Низкая доля принятия,
- Большое время смешивания цепи.

Улучшенное сэмплирование

- $\beta(G_{ij}, G_t) = \min\{1, \frac{P^*(G_{ij}|D)}{P(G_t|D)}\},$
- Сэмплируем G_{ij} с вероятностью $P(G_{ij}) = b_{ij} = q_{ij} \cdot \beta(G_{ij}, G)$. С вероятностью $1 - \sum_{ij} b_{ij}$ остаемся в состоянии G_t .
- $G_{t+1} = G_{ij}$, если G_{ij} — ациклический.

RAV обращение ребра

- После обращения ребра (i, j) , сэмплируем $\text{Pa}_G(X_i)$ и $\text{Pa}_G(X_j)$, пропорционально $\text{LocalScore}(X_i | \text{Pa}_G(X_i))$, $\text{LocalScore}(X_j | \text{Pa}_G(X_j))$.

Определение

- G_0 — граф без ребер,
- переходы:
 1. добавление в G_t ребра (i, j) , не нарушая ацикличность,
 2. окончание генерации (переход в s_f),
- траектория $\tau = (G_0, G_1, \dots, G_T, s_f) = (G_0, G_1, \dots, G_T, G_{T+1})$
- награда состояния $R(G) = p(G, D)$,
- $P_\theta(G'|G)$ - функция прямых вероятностей переходов,
- $P_B(G|G')$ - функция обратных вероятностей переходов.


Условие детального баланса

$$R(G')P_B(G|G')P_\theta(s_f|G) = R(G)P_\theta(G|G')P_\theta(s_f|G')$$

Генеративные потоковые сети

Оптимизационная задача

$$\mathcal{L}(\theta) = \sum_{G \rightarrow G'} \log \left[\frac{R(G') P_B(G|G') P_\theta(s_f|G)}{R(G) P_\theta(G|G') P_\theta(s_f|G')} \right]^2 \rightarrow \min_{\theta}$$



Вид генеративной потоковой сети над байесовскими сетями

Постановка базового эксперимента

Модель

- $\mathbf{X}$ — вектор категориальных случайных величин,
- $P(G)$ — равномерное распределение,
- $P(\theta|G)$ — распределение Дирихле.

BDeuScore

$$\text{BDeu}(X_i | \text{Pa}_G(X_i)) = \prod_{j=1}^{q_i} \frac{\Gamma(\alpha_0)}{\Gamma(\alpha_0 + n_{ij})} \prod_{k=1}^{r_i} \frac{\Gamma(n_{ijk} + \alpha_0)}{\Gamma(\alpha_0)}$$

где q_i — количество конфигураций родителей вершины X_i , r_i — количество возможных значений переменной X_i , n_{ijk} — количество наблюдений с $X_i = k$ и j — ой конфигурацией родителей, n_{ij} — количество наблюдений, где родители X_i находятся в конфигурации j , α_0 — априорный параметр.

Постановка базового эксперимента

Данные

- Asia: с 8 бинарными переменными, всего 1000 наблюдений.
- Sachs: с 11 тернарными переменными, всего 5400 наблюдений.

Метрика

$$\text{MAD} = \max_{ij} |\hat{p}_{ij} - p_{ij}|,$$

где $\hat{p}_{ij}$ — оценка вероятности существования зависимости j от i , по сгенерированным графам. p_{ij} — точные значения вероятностей, полученные с помощью экспоненциального алгоритма.

Дальнейшие планы

- Провести эксперименты сравнения двух подходов,
- Улучшить качество генеративных потоковых сетей, с помощью использования глобальных переходов.